

Sprint IA | Bloque 1 - Parte II

Contextualización, investigación relámpago y caso de impacto · Fundamentos de IA

Equipo: MESSI **Rama asignada:** Redes neuronales

Proyecto MESSI: motor de alerta temprana de riesgo de reprobación escolar.

Integrantes y roles

Integrante	Rol y responsabilidad
Marco Antonio Osorio Hernandez	Líder técnico / desarrollador: integración del modelo y la aplicación.
Ismael Hernández Jiménez	Investigador / analista: caso de uso, datos y fuentes.
Víctor Manuel Jiménez Suárez	QA / pruebas: evaluar alertas, errores y calidad de los datos.
Yokio Yosafat Vazquez Carrillo	Vocero principal: exposición y comunicación del proyecto.
Salomón Alvarez Gomez	Desarrollo / documentación: interfaz, archivos y guía de uso.

1. Aterrizaje a un caso de impacto

Caso elegido: apoyar a docentes y tutores de una escuela a identificar, al terminar el primer parcial, estudiantes que podrían reprobado una asignatura al cierre del periodo. El prototipo se limitará a una asignatura y un nivel escolar.

Problemática: revisar por separado calificaciones, asistencia y tareas puede dificultar la detección oportuna de estudiantes que necesitan acompañamiento. Una alerta conjunta permitiría revisar cada caso antes del cierre del curso.

Objetivo e impacto esperado: estimar el riesgo y facilitar la asignación de tutorías, asesorías o seguimiento de tareas. La reducción de reprobación es una meta por comprobar, no un resultado ya obtenido.

Entrada: CSV con identificador anónimo, calificación del primer parcial, porcentaje de asistencia y porcentaje de tareas entregadas hasta ese corte. El ID solo identificará el registro; no será una variable predictora.

Salida: puntuación de riesgo, alerta según un umbral validado y resumen de los indicadores académicos para revisión del tutor. Los indicadores observados no se presentarán como causas demostradas ni como explicación exacta de la red.

Datos para aprender: registros de periodos anteriores con esas mismas variables al primer parcial y el resultado final aprobado/reprobado según el criterio de la escuela. El resultado final será la etiqueta de entrenamiento; nunca una entrada para predecir.

Justificación: una red neuronal puede aprender combinaciones no lineales entre indicadores. Elegimos el caso por su utilidad para el acompañamiento y su salida comprobable; compararemos la red con una regla simple para verificar si aporta valor.

Ejemplo ficticio: A017 tiene 5.8/10 en el primer parcial, 70% de asistencia y 50% de tareas entregadas. MESSI procesaría esas entradas para orientar la revisión del tutor. No se asigna un riesgo numérico: el modelo aún no está entrenado.

Uso previsto: orientar apoyo académico con revisión humana. Las alertas no modificarán calificaciones ni aplicarán sanciones. La demostración usará datos sintéticos; los datos reales requerirán acceso autorizado y protección de identidad.

MESSI | Herramientas y alcance

Selección del stack para el Bloque 2 · Propuesta de implementación

2. Stack elegido y justificación

Herramienta	Uso y motivo de elección
Python + pandas	Cargar el CSV, comprobar rangos y detectar faltantes o duplicados. Permiten preparar los datos tabulares.
scikit-learn [1, 2]	Entrenar una red MLPClassifier y estandarizar variables con StandardScaler dentro de un Pipeline.
Streamlit	Crear una interfaz en Python para cargar datos, consultar alertas y descargar un reporte para el tutor.

Modelo propuesto: perceptrón multicapa (MLP) supervisado: tres entradas numéricas, una capa oculta inicial de ocho neuronas y una salida binaria. Aprenderá pesos con ejemplos etiquetados de aprobado/reprobado. Esta configuración se ajustará con validación; no requiere un modelo generador de texto.

Flujo de uso: cargar datos del primer parcial → validar y transformar → estimar riesgo → mostrar alerta e indicadores → revisión del tutor y propuesta de apoyo.

3. Prototipo mínimo y comprobación

Disponibilidad de datos: aún no hay un conjunto escolar confirmado. Los datos sintéticos servirán para demostrar el funcionamiento, pero no demostrarán capacidad de predecir casos reales. Los registros con datos insuficientes se marcarán para revisión.

Pruebas previstas: separar entrenamiento, validación y prueba; reservar periodos posteriores y evitar repetir alumnos entre conjuntos. Ajustar el escalado solo con entrenamiento y usar únicamente datos disponibles al primer parcial. [2]

Evaluación: medir recall (qué proporción de quienes reprobaron fue detectada), precisión de las alertas y matriz de confusión. Elegir el umbral en validación según falsas alarmas y casos omitidos; compararlo con una regla basada en la nota parcial. Revisar diferencias de error entre grupos. No hay métricas obtenidas todavía. [3]

4. Exposición del proyecto y del stack | 3 minutos

Yokio (30 s): presentar MESSI y su objetivo. **Ismael (40 s):** explicar el problema escolar y los datos. **Marco (50 s):** justificar la red neuronal y las herramientas. **Salomón (30 s):** mostrar el flujo y el ejemplo. **Víctor (30 s):** explicar pruebas, límites y revisión del tutor. Todos deben poder justificar las decisiones.

Fuentes consultadas | 28 de septiembre de 2026

scikit-learn: [1] MLPClassifier; [2] Prevención de fuga de datos; [3] Métricas de clasificación.
Herramientas: pandas y Streamlit.

MESSI | Bitácora de prompts

Selección de consultas de investigación y definición del proyecto

Los prompts proceden de este chat; se normalizó la ortografía. La asignación identifica al responsable de revisar y explicar cada entrada, no a su autor original. La revisión individual del equipo queda pendiente.

Las primeras consultas corresponden a la exploración inicial. El caso vigente es riesgo de reprobación escolar. No se registran solicitudes de creación de archivos ni correcciones de nombres.

1. Ismael Hernández Jiménez | Requisitos y problemática

Prompt: «¿El documento mencionó algo de una problemática? Me refiero al documento para hacer la presentación.»

Solicitud: Precisar si la actividad exige identificar el problema que aborda la rama de IA.

Ajuste / verificación: Se comprobó en los PDF de la tarea que se requiere un caso real o realista y justificar su elección.

2. Marco Antonio Osorio Hernandez | Exploración de aplicaciones

Prompt: «¿Qué problemas resuelven las redes neuronales en este caso? Estaba pensando en una gama desde el sector salud hasta el sector laboral.»

Solicitud: Explorar sectores y concretar un problema para el proyecto.

Ajuste / verificación: El usuario reorientó después el caso al riesgo de reprobación escolar. La ficha recoge ese cambio; su eficacia aún no está validada.

3. Víctor Manuel Jiménez Suárez | Revisión de preguntas

Prompt: «¿Y las preguntas a responder?»

Solicitud: Identificar las preguntas obligatorias para comprobar la cobertura de la actividad.

Ajuste / verificación: El Sprint solicita problema, entrada/salida y ejemplo industrial; la Parte II añade caso y stack. Se verificó la diferencia entre ambos documentos.

4. Yokio Yosafat Vazquez Carrillo | Enfoque de la exposición

Prompt: «No sé si tenemos que explicar qué son las redes neuronales o solo responder las preguntas.»

Solicitud: Delimitar cuánto fundamento teórico incluir y qué debe justificarse al exponer.

Ajuste / verificación: Se priorizaron las respuestas y una explicación breve del modelo. La Parte II establece 2 a 5 minutos; la distribución propuesta suma 3 minutos.

5. Salomón Álvarez Gomez | Framework y herramientas

Prompt: «¿Para este caso conviene meter un framework? Y, si sí, ¿cuál conviene?»

Solicitud: Elegir herramientas para la interfaz y para entrenar el modelo de riesgo escolar.

Ajuste / verificación: Se distinguió Streamlit (framework) de scikit-learn (biblioteca para la MLP). Se consultó documentación oficial; la implementación sigue pendiente.

Fuentes de contraste: Sprint_Ramas_IA.pdf; Ficha_Bloque1-Parte II.pdf; documentación oficial de Streamlit y scikit-learn enlazada en la página 2.